RNA二级结构预测汇总

- RNA二级结构预测汇总
  - 1. RNA 二级结构预测：大家都在做什么实验
    - 实验一：bpRNA 实验
    - 实验二： RNAStralign 实验
    - 实验三：泛化性检验 bpRNA-new 与 ArchiveII
    - 主流模型在标准基准数据集上的性能对比
    - RNA 预训练语言模型对比
  - 2. 大家都做了哪些创新
    - 2.1 数据增强（Data Augmentation）
    - 2.2 大规模 RNA 预训练模型（Pre-trained RNA Models）
    - 2.3 融合学习（Ensemble Learning）
  - 3. 对RNA二级结构预测工作的思考
    - 3.1 针对 bpRNA 数据集的家族偏差分析
    - 3.2 生成式模型研究
    - 3.3 RNA二级结构问题范式的转变
  - 总结：RNA二级结构预测，我们走到了哪里?

1. RNA 二级结构预测：大家都在做什么实验

实验一：bpRNA 实验

在 RNA 二级结构预测的深度学习领域，最关键的一篇奠基型论文就是 **SPOT-RNA** 。这篇论文对 bpRNA 数据集做了一些处理——bpRNA-1m 是一个非常大的 RNA 数据集，包含数万条来自不同家族的 RNA 序列。

SPOT-RNA 论文使用 CD-HIT 工具，筛选掉 bpRNA-1m 数据集中相似度在 80% 以上的 RNA，最终保留的数据是13419条。然后按照 Train Set、Test Set 和 Validation Set划分，10,814 个序列用于训练，1,300 个序列用于验证，1,305 个序列用于独立测试。这个实验也是 RNA 二级结构的一个经典实验，也就是说，你需要在 bpRNA 的 Test Set 上取得一个比较好的成绩。

实验二： RNAStralign 实验

RNAStralign。该数据集也是一个比较大的数据集，包含约 37,149 条唯一序列。最早是E2Efold(ICLR2020)这篇论文对该数据做了处理清洗后的有效数据约为 30451 条，被划分为Train 24,360 条， Validation 3,045 条，Test 3,046 条，覆盖了 8 个主要 RNA 家族，包括 16S rRNA、5S rRNA、tRNA、Group I Introns、RNase P RNA、SRP RNA、tmRNA 和 Telomerase RNA

实验三：泛化性检验 bpRNA-new 与 ArchiveII

bpRNA-new。它是专门用于评估 RNA 二级结构预测模型跨家族泛化能力的基准数据集，基于 Rfam 14.2 版本构建，核心价值在于其包含了在原始 bpRNA-1m 数据集（基于 Rfam 12.2）发布之后新发现的约 1,500 个 RNA 家族 。其数据规模约为 5,401 条序列，序列长度通常限制在 500 nt 以内。这个数据集就是用来验证我们深度学习模型泛化性的——你在 bpRNA 数据集上面做训练，就要测试在 bpRNA-new 这个数据集上面的泛化性。

ArchiveII 数据集包含了 10 个不同的 RNA 家族，总计 3,975 条 RNA 序列。序列长度覆盖范围很广，从最短的 28 个核苷酸（nt）到最长的 2,968 个核苷酸不等。包含的 RNA 家族： 主要包括 5S rRNA、16S rRNA、tRNA、tmRNA、RNase P RNA、SRP RNA、group I intron 等经典且结构已知的 RNA。由于它包含了多个不同的家族且去除了高度冗余的序列，它已经成为检验 RNA 预测模型泛化能力和避免过拟合的行业标准之一。

主流模型在标准基准数据集上的性能对比

模型	类型	发表年份	RNAStralign F1	ArchiveII F1	TS0 F1	bpRNA-new F1	特点	数据来源
PriFold	Transformer+协变性	2025 (AAAI)	0.988	0.952	0.770	—	协变性数据增强，跨家族 SOTA	PriFold 原论文
UFold	U-Net (FCN)	2022 (NAR)	0.977	0.905	0.654	0.636	极速推理 160ms，家族内领先	UFold 基准评估

模型	类型	发表年份	RNAStralign F1	ArchiveII F1	TS0 F1	bpRNA-new F1	特点	数据来源
RNAformer	轴向注意力	2024	—	—	0.725	—	第一个提出轴向注意力，轻量高效	RNAformer 原论文
RNADiffFold	扩散模型	2025	—	0.880	0.711	0.659	多构象生成，长程配对强	RNADiffFold 原论文
DEPfold	双仿射注意力 +依赖解析	2025 (ICLR)	0.985	0.920	0.676	0.621	双仿射注意力 +最优树解码，长程配对 SOTA	DEPfold 原论文
RiNALMo	RNA 语言模型（Transformer）	2024 (Bioinformatics)	—	0.72	0.75	-	通用 RNA 表征，注意力图与结构对齐度 69.5%	RiNALMo 原论文
E2Efold	Transformer+约束	2020 (NeurIPS)	0.821	0.686	0.130	0.036	端到端硬约束，跨家族泛化极弱	UFold 基准评估
SPOT-RNA	ResNet+LSTM	2019 (NAR)	—	0.711	0.619	0.620	开创性深度学习工作	UFold 基准评估

注：

- F1=调和平均，范围 0–1，越高越好；"—" 表示该论文未报告此指标或该模型不适用于此数据集
- **RNAStralign**：家族内测试集，覆盖 8 个主要 RNA 家族，衡量模型对已见 RNA 家族的预测能力
- **ArchiveII**：经典独立测试集，包含 10 个 RNA 家族共 3,975 条序列，用于评估模型的家族内泛化能力
- **TS0**：bpRNA 标准跨家族测试集（1,305 条序列），基于 Rfam 12.2，评估模型对未见 RNA 家族的预测能力
- **bpRNA-new**：跨家族泛化基准（5,401 条序列），基于 Rfam 14.2，包含约 1,500 个新发现家族。
- DEPfold、PriFold、RNAformer、RNADiffFold、RiNALMo、的数据均来自于它们的原论文。其余模型（E2Efold、UFold、SPOT-RNA）的 ArchiveII/TS0/bpRNA-new 数据来自 UFold 的统一基准评估

RNA 预训练语言模型对比

模型	参数量	预训练数据	预训练任务	RNAStralign F1	ArchiveII F1	TS0 F1	bpRNA-new F1	特点	数据来源
RiNALMo	650M	RNAcentral	MLM	—	0.72	0.747	-	通用 RNA 表征，注意力图与结构对齐度 69.5%	RiNALMo 原论文
ERNIE-RNA	86M	配对约束预训练	结构感知 MLM	—	-	-	-	配对约束预训练，零样本预测超越 RNAfold	ERNIE-RNA 原论文
RNA-FM	100M	RNAcentral	MLM	—	0.941	0.704	-	早期 RNA 语言模型，跨家族泛化弱	RNA-FM 原论文

注：

- MLM = Masked Language Modeling（掩码语言模型），是 BERT 式预训练的核心任务
- ERNIE-RNA 这篇论文在数据展示上比较奇怪，分为attn-map, froze等情况，数据不纳入表格。

2. 大家都做了哪些创新

我们从上面的实验情况可以很显然地发现，RNA 二级结构预测存在一个很大的泛化性问题。在 RNAStralign 以及 ArchiveII 这两个数据集上，这个问题还没有那么明显，但在 bpRNA 数据集上，其泛化性问题非常严重。即使是目前最新的 SOTA 模型，其实也仅仅是将 F1 Score 刷到了 0.77。所以我们就想知道，为了提高这个泛化性，大家的论文都做了哪些改进或者创新？大家的创新点都是什么？

这里我总结几条：

2.1 数据增强（Data Augmentation）

我们主要关注的是 **PriFold** 这篇论文，发表在 AAAI 2025 上。该论文利用了 RNA 二级结构的共变特性：在碱基配对中，如果配对的两个碱基同时发生变化——例如从 A-U 变成 G-C——其最终生成的二级结构其实是保持不变的。这是因为 Watson-Crick 配对中的补偿性突变维持了碱基配对的热力学稳定性，虽然序列变了，但结构没变。

通过这种方法，我们可以调整数据替换的概率，从而构造出更加多样化的训练数据，天然地增强了数据多样性。此外，这种共变特性有生物学知识作为背书，因此该创新方案受到了广泛认可。PriFold 还进一步将这种协变性信息集成为配对概率矩阵，直接增强注意力机制的结构感知力，让模型学到的是"结构规则"而不是"序列记忆"。

除了 PriFold，还有一些其他的数据增强思路：

- **DivideFold** 采用随机突变策略，将 0–10% 的碱基对随机替换为其他标准配对（AU、GC、GU），强制模型学习结构规则而非记忆序列。
- **UFold** 和 **RNADiffFold** 则通过 10–30% 的核苷酸随机突变，并使用传统热力学工具 Contrafold 生成伪标签进行监督学习。

这些方法的核心思想都是一致的：**在不破坏二级结构的前提下，增加训练数据的序列多样性**。

2.2 大规模 RNA 预训练模型（Pre-trained RNA Models）

这是目前非常普遍的工作。虽然目前标注的 RNA 二级结构数据较少，但未标注的 RNA 序列数据非常丰富。因此，大家会在这些海量序列上预训练一个 RNA 基础模型。

其训练方法与 BERT 类似：基于 Transformer 架构，通过Mask RNA 序列中的部分碱基来训练掩码语言模型。这样可以将 RNA 序列转换成一个 L × hidden_size 的向量。

这种方法的训练通常分为两个阶段：

1. **第一阶段：预训练Encoder**。在海量无标注序列上，通过掩码语言模型任务学习 RNA 序列的内在规律和"折叠语法"。
2. **第二阶段：端到端微调**。提取编码器输出的 RNA 序列特征，用于二级结构预测。在具体预测时，主要方法是将 L × dimension 的一维向量扩展为 L × L × dimension 的二维特征，然后进行结构预测（可以是逐位置预测或其他方法）。

这个方向的代表工作包括：

模型	参数规模	特点
RNA-FM	100M	最早将蛋白质语言模型范式迁移到 RNA 领域的工作之一
RiNALMo	650M	通用 RNA 语言模型，注意力图与真实二级结构的对齐度高达 69.5%，跨家族泛化能力强
ERNIE-RNA	86M	百度 2024 年提出，引入"配对限制"机制将结构感知约束嵌入预训练，零样本预测超越 RNAfold

这些预训练模型的共同优势在于：它们在海量无标注序列上学习到了 RNA 序列的通用表征，即使面对从未见过的 RNA 家族，也能给出相对合理的结构预测。这本质上是一种**通过大数据来缓解泛化性问题**的手段。

2.3 融合学习（Ensemble Learning）

目前已经存在很多预测模型，包括深度学习模型、传统的热力学相关模型，以及不同架构的二级结构预测模型。我们可以通过一个集成模块将这些不同模型的特征进行融合。

该方法基于一个假设：由于不同模型的架构不同，它们在学习结构特征时各有侧重：

- **热力学模型**（如 RNAfold）基于物理能量参数，对典型结构预测稳定；
- **深度学习模型**（如 UFold）从数据中学习模式，能捕捉非典型配对；
- **不同架构的神经网络**（CNN vs Transformer）关注的序列尺度也不同。

通过融合这些侧重点不同的特征，能够有效提升最终的特征表示能力。

这方面的代表性工作是 **MetaRNA**。MetaRNA 采用元预测器框架，旨在通过整合多个基础预测器来提升预测精度。该方法能有效弥合热力学模型与统计模型之间的差距，减少单一算法的系统偏差。

3. 对RNA二级结构预测工作的思考

3.1 针对 bpRNA 数据集的家族偏差分析

首先第一点，我们可以针对 bpRNA 数据集系统性的家族偏差做一些分析。目前大家都在使用经过 CD-HIT 工具处理后的 bpRNA 数据集进行训练和测试，**有没有可能这个数据集本身就是有问题的?**

我们之所以有这样的假设，是因为 CD-HIT 是一种基于聚类算法的工具。它的核心假设是：如果 RNA 的序列相似，那么其结构和功能就相似。因此，它在判定相似度时，只看 RNA 序列是否相似，而不管其二级结构。这会导致以下几个缺陷：

1. 协同突变导致误判： RNA 二级结构的稳定性是由碱基配对维持的。当配对中的一个碱基发生突变时，与它配对的另一个碱基往往也会发生相应的突变（协同突变）。这种突变发生后，RNA 的二级结构其实保持不变。但由于 CD-HIT 对序列差异非常敏感，就会把这些结构相同但序列不同的样本判定为不相似。

2. 结构保守性被忽略： 对于同一家族的 RNA，虽然在进化过程中会发生很多序列变异，但它们整体的二级结构（例如三叶草结构或茎环排列）其实是非常保守的。也就是说，虽然序列有分歧，但结构依然相似。

总结来说，使用 CD-HIT 工具进行去冗余会带来一个问题：在训练集中，常见家族的 RNA 序列非常多，因为它们有很多种变异。一旦序列发生变异，尽管它们的结构非常相似，也会被 CD-HIT 分到不同的聚类中心。这导致同一个家族的样本量在训练集中占比过大，使得模型在训练过程中，主要去学习了这些特定家族的模式。当测试集出现一个全新的 RNA 家族时，模型就完全不知道该怎么处理了——**这就是泛化性差的根本原因**。

3.2 生成式模型研究

此外，我们也可以做一些生成式模型相关的研究工作。

目前主流且效果较好的 SOTA 模型，其实采用的还是**判别式模型**。也就是说，比如要进行 RNA 配对，它是一个 L × L × Dimension 的特征，每一个特征都负责一个位置的判别。最后通过一个激活函数来判断当前位置，并设定一个阈值：大于阈值的就是 1（配对），小于阈值的就是 0（不配对）。

这种判别式模型天然存在一个问题，就是多样性不够好，无法产生多样化的 RNA 序列。相比之下，生成式模型可以算作是一个创新点，目前相关的论文还比较少。**那么，生成式模型和 SOTA 的差距到底有多大呢?**

- 在二级结构预测中，生成式模型 **RNADiffFold** 在跨家族泛化（F1=0.711）和长程配对预测（F1=0.739）上显著优于判别式模型 UFold（分别为 0.630 和 0.687）。这说明生成式模型在泛化性方面天然具有优势——扩散模型的去噪过程本身就是一种结构精炼，能够从噪声中逐步恢复出合理的配对模式，而不是像判别式模型那样做一个"一刀切"的二分类。
- 然而，在家族内预测任务中，判别式模型 UFold（0.91）仍保持领先于 RNADiffFold（0.88）。这说明生成式模型目前还无法在"见过"的家族上完全超越判别式模型。

不过，这与当前的 SOTA 模型相比还是有很大的差距。但可以确定的是，生成式模型在跨家族泛化和长程配对这两个"老大难"问题上已经展现出了独特的优势，是一个值得深入探索的方向。

3.3 RNA二级结构问题范式的转变

这个方向的代表工作是 **DEPfold（ICLR 2025）**。DEPfold 正是抓住了这一本质联系。它从 NLP 的依存句法分析汲取经验，应用于RNA二级结构预测。换句话说，当你面对一个生物计算问题时，不要只盯着生物学的表象——去思考这个问题在数学上到底"长什么样"。它是树吗？是图吗？是序列标注吗？是匹配问题吗？一旦你找到了它在另一个学科中的"数学同胚"，你就可以直接借用那个学科几十年积累的成熟工具。

DEPfold 的成功不是偶然的。它告诉我们，在深度学习"大力出奇迹"的时代，最稀缺的不是算力，不是数据，而是**对问题结构的深刻洞察**。当一个领域的所有人都在用差不多的架构、差不多的数据、做差不多的实验时，与其在同一个范式内卷，不如跳出来问一句：**这个问题，在数学上到底等价于什么？** 找到这个等价关系，你就能用一个领域的成熟理论去解决另一个领域的难题——这种跨学科的"范式翻译"，恰恰是顶级会议最看重的那种"有智慧的创新"。

总结：RNA二级结构预测，我们走到了哪里?

写到这里，我试图用一句话来概括 RNA 二级结构预测领域的现状：**我们已经在家族内预测上做得足够好（F1 > 0.98），但跨家族泛化仍然是一个没有解决的"硬骨头"（F1 最高 0.77）。**

回顾 RNA 二级结构预测这个领域的发展历程，从 2019 年 SPOT-RNA 开创性地将深度学习引入这个方向，到 2025 年 DEPfold、PriFold、RNADiffFold 等工作的百花齐放，在跨家族泛化这个核心指标上的数字提醒我们，单靠扩大模型规模、增加训练数据、微调网络架构，可能已经逼近了当前范式的能力边界。

我个人的判断是：RNA 二级结构预测的下一个突破，不太可能来自一个更深的 ResNet 或更大的 Transformer，而更可能来自**对问题本身的重新定义**——就像 DEPfold 将结构预测重新定义为句法分析一样。无论是从生成式建模、因果推断、图论优化还是形式语言理论的角度切入，关键都在于跳出"序列→矩阵"

的条件分布拟合框架，去寻找 RNA 折叠的真实生成机制。